

Plano de Leitura Teórica — PageRank & Perron-Frobenius

Amy N. Langville & Carl D. Meyer — "Google's PageRank and Beyond: The Science of Search Engine Rankings"

Datasets Reais para Teste do Algoritmo (Capítulo 14)

O livro indica, na seção 14.1 (datasets pequenos, para começar) e 14.2 (datasets grandes, para estudo mais sério), fontes de grafos reais de páginas web — úteis para testar a implementação além dos grafos sintéticos gerados aleatoriamente.

Dataset	# páginas	# links	Fonte	Porte
Movies	451	713	Website 1 (Tsaparas)	Pequeno
Censorship	562	736	Website 1 (Tsaparas)	Pequeno
Abortion	1.693	4.325	Website 1 (Tsaparas)	Pequeno
Genetics	2.952	6.485	Website 1 (Tsaparas)	Pequeno
EPA	4.772	8.965	Website 2 (Cornell)	Pequeno
Hollins	6.012	23.875	Website 3 (Massey)	Pequeno
California	9.664	16.150	Website 2 (Cornell)	Pequeno
Stanford University sites	0,28 milhão	2,3 milhões	Website 5 (Kamvar/Stanford)	Grande
Stanford-Berkeley sites	0,68 milhão	7,6 milhões	Website 5 (Kamvar/Stanford)	Grande
23 U.S. University sites	3,0 milhões	23,9 milhões	Website 6 (Cybermetrics/WLV)	Grande
38 Australian University sites	2,3 milhões	19,8 milhões	Website 6 (Cybermetrics/WLV)	Grande

Estratégia sugerida de teste

1.

Grafos pequenos (Movies, Censorship) → validar corretude do método direto (eliminação gaussiana), já que o custo $O(n^3)$ ainda é tratável nessa escala.

2.

Grafos médios (Genetics, EPA, Hollins, California) → comparar tempo de execução entre método direto e power iteration, evidenciando a diferença de escalabilidade.

3.

Grafos grandes (Stanford, University sites) → praticamente inviáveis para o método direto em Python puro; servem para demonstrar, na prática, por que o power iteration é a escolha real usada pelo Google — ótimo argumento empírico para a seção de discussão da IC.

Fase 1 — Fundamentação Teórica Pura (Capítulo 15)

	Seção	Foco	Profundidade
1	15.1 — Linear Algebra	Autovalores, autovetores, multiplicidade algébrica/geométrica, diagonalização	Detalhada
2	15.2 — Perron-Frobenius Theory ★	O teorema central: irredutibilidade, aperiodicidade, autovalor dominante	Detalhada
3	15.3 — Markov Chains	Distribuição estacionária, ergodicidade, "surfista aleatório" formalizado	Detalhada
4	15.4-15.8 — Complementação, Censoring, Aggregation/Disaggregation	Técnicas de decomposição para matrizes grandes	Panorâmica (aprofundar só se for discutir escala/eficiência)

Fase 2 — Aplicação ao PageRank (Capítulo 4)

	Seção	Conecta com o que já foi feito
5	4.1 — Fórmula original de somatório	Primeira intuição, antes de matrizes
6	4.2 — Representação matricial	matriz_adjacencia, matriz_estocastica
7	4.3 — Problemas do processo iterativo	Dangling nodes — bug já resolvido

8	4.4 — Teoria de Markov Chains aplicada	Conecta 15.3 com o contexto específico
9	4.5 — Ajustes ao modelo básico	Damping factor / matriz_google
10	4.6 — Computação do vetor PageRank	power_iteration
11	4.7 — Teorema e prova do espectro da matriz Google ★	Prova formal de $\lambda=1$ dominante

Fase 3 — Parâmetros do Modelo (Capítulo 5)

	Seção	Conecta com o que já foi feito
12	5.1 — O fator α	Por que $d = 0.85$ especificamente
13	5.2 — Matriz de hyperlink H	Matriz estocástica
14	5.3 — Matriz de teletransporte E	A parte $(1-d)/n \cdot J$

Fase 4 — O Método Direto Formalizado (Capítulo 7)

	Seção	Conecta com o que já foi feito
15	7.1 — Propriedades de $(I-\alpha S)$	Análise formal da matriz invertida
16	7.2 — Propriedades de $(I-\alpha H)$	Variante antes do tratamento de dangling
17	7.3 — Prova do sistema linear esparso do PageRank ★	Fundamenta o método de eliminação gaussiana

Fase 5 (Opcional) — Sensibilidade e Implementação em Escala

	Capítulo	Relevância
18	Cap. 6 — Sensibilidade do PageRank	Como o resultado muda com α , H, v — bom para discutir robustez
19	Cap. 8 — Implementação em larga escala	Conecta com testes de tempo ($n = 200$ a 2000)

Lógica por trás da ordem

1. Teoria geral primeiro (Cap. 15) → construção do arcabouço matemático sem ainda estar amarrado à aplicação específica.

2. Aplicação ao PageRank (Cap. 4) → a teoria geral sendo especializada para o problema.

3. Parâmetros (Cap. 5) → aprofunda decisões de modelagem já tomadas na prática ($d = 0.85$).

4. Sistema linear (Cap. 7) → formaliza especificamente o método direto (eliminação gaussiana).

5. Extras (Cap. 6 e 8) → só se a IC crescer para discutir sensibilidade/escala.